



# Comentário de Conjuntura

## Estimando um modelo de correção de erros entre a Produção de Veículos e a Produção Industrial

Vítor Wilher, Mestre em Economia e Cientista de Dados

07 de janeiro de 2020

### Abstract

Nesse comentário, fazemos uma análise de cointegração entre a produção de veículos da ANFAVEA e a produção industrial divulgada pelo IBGE.

### Contents

<b>1</b>	<b>Pacotes e atualizações</b>	<b>2</b>
<b>2</b>	<b>Coleta de Dados</b>	<b>2</b>
<b>3</b>	<b>Visualização de Dados</b>	<b>2</b>
<b>4</b>	<b>Cointegração</b>	<b>4</b>
<b>5</b>	<b>Comentário</b>	<b>5</b>
	<b>Referências</b>	<b>6</b>

## 1 Pacotes e atualizações

```
library(ggplot2)
library(xtable)
library(forecast)
library(gridExtra)
library(readxl)
library(dplyr)
library(magrittr)
library(scales)
library(sidrar)
library(vars)
library(dynlm)
library(stargazer)
```

## 2 Coleta de Dados

```
# Produção de Veículos
url = 'http://www.anfavea.com.br/docs/SeriesTemporais_Autoveiculos.xlsm'
download.file(url, destfile = 'veiculos.xlsm', mode='wb')
veiculos = read_excel('veiculos.xlsm', col_types = c('date',
                                                    rep('numeric', 25)),
                    skip=4)
veiculos$...1 = as.Date(veiculos$...1, format="%d/%m/%Y")
colnames(veiculos)[1] = 'dates'
veiculos = veiculos[!rowSums(veiculos[, -1]) == 0, ]

## indústria
table1 = get_sidra(api = '/t/3653/n1/all/v/3134,3135/p/all/c544/all/d/v3134%201,v3135%201')


geral_sa = table1$Valor[table1$`Variável (Código)` == 3134 & table1$`Seções e atividades industriais (CNAE 2
geral = table1$Valor[table1$`Variável (Código)` == 3135 & table1$`Seções e atividades industriais (CNAE 2

date = seq(as.Date('2002-01-01'), as.Date('2019-12-01'), by='1 month')
industria = tibble(dates=date, geral, geral_sa)
```

## 3 Visualização de Dados

```
filter(veiculos, dates > '2014-01-01') %>%
  ggplot(aes(x=dates, y=Produção...5/1000))+
  geom_line(size=.8)+
  scale_x_date(breaks = date_breaks("2 months"),
              labels = date_format("%b/%Y"))+
  theme(axis.text.x=element_text(angle=45, hjust=1))+
  labs(x='', y='Mil', title='Produção de Veículos',
       caption='Fonte: ANFAVEA')
```


### Produção de Veículos



Fonte: ANFAVEA

```
filter(veiculos, dates > '2014-01-01') %>%
  ggplot(aes(x=dates, y=Exportação...6/1000))+
  geom_line(size=.8)+
  scale_x_date(breaks = date_breaks("2 months"),
               labels = date_format("%b/%Y"))+
  theme(axis.text.x=element_text(angle=45, hjust=1))+
  labs(x='', y='Mil', title='Exportação de Veículos',
       caption='Fonte: ANFAVEA')
```


### Exportação de Veículos



Fonte: ANFAVEA

```
filter(veiculos, dates > '2002-01-01') %>%
  inner_join(industria, by='dates') %>%
  ggplot(aes(x=Produção...5/1000, y=geral))+
  geom_point()+
  geom_smooth(se=FALSE, method='lm', colour='red')+
  theme(axis.text.x=element_text(angle=45, hjust=1))
```

```
labs(x='Produção de Veículos', y='Produção Industrial',
     title='Produção de Veículos vs. Produção Industrial',
     caption='Fonte: analisemacro.com.br')
```



## 4 Cointegração

```
data = filter(veiculos, dates > '2002-01-01') %>%
  inner_join(industria, by='dates') %>%
  dplyr::select("Produção...5", geral)

colnames(data) = c('veiculos', 'industria')
```

```
### Passo 01
reg <- lm(industria~veiculos, data=data)
ur <- ur.df(resid(reg), type='trend')
ur@teststat
```

```
##          tau3      phi2    phi3
## statistic -5.429977 9.874461 14.8087
```

```
unitrootTable(statistic='t', trend='ct')
```

```
##      0.010  0.025  0.050  0.100  0.900  0.950  0.975  0.990
## 25 -4.374 -3.945 -3.603 -3.238 -1.146 -0.820 -0.525 -0.173
## 50 -4.153 -3.795 -3.502 -3.181 -1.198 -0.882 -0.594 -0.251
## 100 -4.052 -3.727 -3.455 -3.153 -1.223 -0.911 -0.627 -0.289
## 250 -3.995 -3.687 -3.428 -3.137 -1.237 -0.929 -0.647 -0.311
## 500 -3.976 -3.673 -3.419 -3.132 -1.242 -0.935 -0.653 -0.318
## Inf -3.958 -3.660 -3.410 -3.127 -1.246 -0.940 -0.660 -0.326
## attr("control")
##      table      trend statistic
## "unitroot"      "ct"      "t"
```

```
### Passo 02
data = ts(data, start=c(2002,01), freq=12)
resid <- ts(resid(reg), start=start(data), freq=12)
ecm <- dynlm(d(industria)~stats::lag(resid,-1)+d(veiculos), data=data)

stargazer(ecm, header=FALSE)
```

Table 1:

	<i>Dependent variable:</i>
	d(industria)
stats::lag(resid, -1)	-0.245*** (0.046)
d(veiculos)	0.0001*** (0.00001)
Constant	0.006 (0.241)
Observations	214
R <sup>2</sup>	0.653
Adjusted R <sup>2</sup>	0.649
Residual Std. Error	3.530 (df = 211)
F Statistic	198.212*** (df = 2; 211)
Note:	*p<0.1; **p<0.05; ***p<0.01

## 5 Comentário

Uma exceção ao caso de regressão espúria visto anteriormente vem à tona quando dois processos aleatórios compartilham a mesma tendência estocástica.<sup>1</sup> Para ilustrar, considere, como Verbeek (2012), duas séries integradas de ordem 1,  $Y_t$  e  $X_t$ , e suponha que exista uma relação linear entre elas, dada por  $Y_t = \beta X_t + \epsilon_{Yt}$ . Isso implica no fato de existir algum valor de  $\beta$  tal que  $Y_t - \beta X_t$  seja integrado de ordem zero, mesmo com as séries originais sendo ambas não estacionárias. Nesses casos, diz-se que as séries são **cointegradas** e as mesmas compartilham a mesma tendência.<sup>2</sup>

Sendo um pouco mais formal, com base em Pfaff (2008), a ideia por trás do conceito de cointegração é \textbf{encontrar uma combinação linear entre duas variáveis }  $I(d)$  de tal sorte que isso leve a uma variável de menor ordem de integração. Isto é,

Os elementos do vetor  $x_t$  são ditos cointegrados de ordem  $d, b$ , denominado por  $x_t \sim CI(d, b)$ , se todos os elementos de  $x_t$  são  $I(d)$  e o vetor  $\alpha (\neq 0)$  existe tal que  $z_t = \alpha' x_t \sim I(d - b)$ , onde  $b > 0$ . O vetor  $\alpha$  é então chamado cointegrante.

<sup>1</sup>Para uma demonstração detalhada, ver Enders (2009).

<sup>2</sup>Observe, por suposto, que a relação entre  $X_t$  e  $Y_t$  poderá ser caracterizada pelo vetor  $[1, -\beta]'$ .

Para os economistas, por exemplo, esse tipo de análise permite estabelecer relações de longo prazo entre variáveis não estacionárias. O problema, por suposto, passa a como estimar o vetor cointegrante e como modelar o comportamento dinâmico das variáveis  $I(d)$ . Para resolver, vamos ilustrar o **método de dois passos de Engle-Granger**, exposto em Pfaff (2008). No primeiro passo, estimamos o seguinte modelo contendo variáveis não estacionárias de mesma ordem de integração<sup>3</sup>

$$y_t = \alpha_1 x_{t,1} + \alpha_2 x_{t,2} + \alpha_K x_{t,K} + z_t \quad (1)$$

para  $t = 1, \dots, T$ , onde  $z_t$  é um termo de erro. O vetor cointegrante  $(K + 1)$   $\hat{\alpha}$  estimado é dado por  $\hat{\alpha} = [1, -\hat{\alpha}^*]'$ , onde  $\hat{\alpha}^* = (\hat{\alpha}_1, \dots, \hat{\alpha}_K)$ . Assim, acaso exista uma relação de cointegração entre as variáveis,  $z_t$  nada mais é do que o erro em relação ao **equilíbrio de longo prazo** entre elas. Nesse caso,  $z_t$  será necessariamente estacionário.<sup>4</sup>

Se conseguirmos evidências de que  $z_t$  é de fato estacionário, podemos passar adiante. O passo seguinte é especificar um **modelo de correção de erros (ECM, no inglês)**. Para simplificar, vamos considerar, como em Pfaff (2008), o caso bivariado, onde  $y_t$  e  $x_t$  são cointegradas, sendo ambas  $I(1)$ . O ECM é então especificado, de forma geral, como segue

$$\Delta y_t = \psi_0 + \gamma_1 z_{t-1} + \sum_{i=1}^K \psi_{1,i} \Delta x_{t-i} + \sum_{i=1}^L \psi_{2,i} \Delta y_{t-i} + \varepsilon_{1,t} \quad (2)$$

$$\Delta x_t = \xi_0 + \gamma_2 z_{t-1} + \sum_{i=1}^K \xi_{1,i} \Delta y_{t-i} + \sum_{i=1}^L \xi_{2,i} \Delta x_{t-i} + \varepsilon_{2,t} \quad (3)$$

onde  $\hat{z}_t$  é o erro do modelo estimado em 1 e  $\varepsilon_{1,t}$   $\varepsilon_{2,t}$  são ruídos brancos. Nesses termos, o ECM na equação 2 implica que mudanças em  $y_t$  são explicadas pela sua própria história, mudanças defasadas em  $x_t$  e pelos erros obtidos da relação de equilíbrio no passo 1. O valor do coeficiente  $\gamma_1$  determina, por suposto, a velocidade de ajustamento e deveria ser sempre negativo. De outra forma, o sistema poderia divergir da sua trajetória de equilíbrio de longo prazo.

## Referências

- Enders, W. 2009. *Applied Econometric Times Series*. Wiley Series in Probability and Statistics. Wiley.
- Pfaff, B. 2008. *Analysis of Integrated and Cointegrated Time Series with R*. Second. New York: Springer.
- Verbeek, M. 2012. *A Guide to Modern Econometrics*. Editora Wiley.

<sup>3</sup>A suposição implícita é que as séries são integradas de primeira ordem.

<sup>4</sup>Pelo fato de  $z_t$  ser uma variável estimada, é preciso testar a presença de raiz unitária com outros valores críticos. No R, esses valores podem ser obtidos com a função `unitrootTable` do pacote **fUnitRoots**.